

智能投研助手 Agent PRD

1. 文档信息

- 项目名称：智能投研助手 Agent
- 文档版本：v1.0
- 编写日期：2026-04-30
- 目标读者：产品经理、后端工程师、算法工程师、前端工程师、测试工程师、运维工程师

2. 项目背景

券商研究与投顾场景中，分析师需要持续处理海量研报、公告、财务报表、行业资讯与内部合规规则，当前主要存在以下问题：

- 信息源分散，检索链路长，人工定位有效内容成本高
- 复杂 PDF、Excel、HTML 文档解析质量不稳定，导致研报表格与关键结论易丢失
- 分析师需要在研究、问答、总结、比对和合规核查之间频繁切换
- 合规校验高度依赖人工逐条比对，影响交付效率与一致性
- 现有工具难以统一接入实时行情、内部数据库、规则库等多类能力

本项目拟建设一个面向投研业务的智能 Agent 平台，围绕“检索、理解、推理、执行、合规”提供统一能力底座。

3. 产品愿景

构建一个可扩展、可部署、可审计的投研智能助手，使分析师能够通过自然语言高效完成信息检索、研究辅助、报告分析、规则核查与多轮任务协同，显著降低重复性工作成本。

4. 产品目标

4.1 业务目标

- 将单篇研报信息提取与初步校验耗时降低 50%
- 提升分析师处理多源资料时的检索效率与问答准确率

- 将合规核查由“纯人工逐条比对”升级为“系统预检 + 人工复核”
- 建立统一 Agent 平台能力，支撑未来跨部门复用

4.2 产品目标

- 支持多轮对话式投研问答
- 支持上传并解析 PDF、Excel、HTML 等文档
- 支持基于查询复杂度的自适应检索
- 支持接入外部工具、内部系统和规则库
- 支持输出可追溯的引用依据与合规检查结果

5. 用户角色

5.1 核心用户

- 研究员/分析师：查询资料、总结结论、提炼观点、辅助写作
- 合规/质控人员：核查输出内容与规则匹配情况
- 投研运营/管理人员：管理知识库、规则库、用户权限和系统运行情况

5.2 次级用户

- IT/平台工程师：维护部署、监控、日志与系统扩展
- 业务系统开发者：通过标准 API/MCP 接入新工具与数据源

6. 核心使用场景

场景 1：研报问答

分析师输入自然语言问题，系统自动识别主题并从研报库、公告库、用户关注标的中检索相关内容，生成带引用的结构化回答。

场景 2：文档摘要与结论提取

分析师上传研报或公告，系统抽取核心观点、财务数据、风险提示和关键结论，输出摘要。

场景 3：跨文档对比分析

分析师要求对多份研报、多个公司公告或不同时点观点进行对比，系统自动做多步检索和聚合分析。

场景 4：合规预检

系统对生成内容执行规则匹配与风险项提示，辅助人工快速完成复核。

场景 5：工具联动

分析师发起需要实时行情、数据库查询或内部规则检索的任务，系统通过工具调用或 MCP Server 自动完成路由与执行。

场景 6：多模态理解

分析师上传包含图表的研报页面或财务图表图片，系统辅助识别趋势、字段和值并纳入回答。

7. 产品范围

7.1 MVP 范围

- 多轮对话问答
- 文档上传与解析
- 向量检索与基础 RAG
- 查询分类与简单路由
- 用户短期记忆
- 长期知识检索
- 合规规则预检查
- FastAPI 标准接口
- Docker 部署

7.2 非 MVP 范围

- 完整语音助手闭环
- 高复杂度多 Agent 协作编排平台
- 全量企业级权限中心与工单系统集成
- 复杂策略回测与交易执行能力

8. 功能需求

8.1 对话与任务入口

FR-01 会话问答

- 用户可通过 API 或前端发起多轮对话
- 系统支持上下文感知回答
- 系统输出回答正文、引用依据、命中的工具/知识源信息

FR-02 任务识别

- 系统识别用户问题属于直接问答、文档分析、跨文档对比、规则核查或工具调用
- 根据任务类型进入不同处理链路

8.2 分层记忆

FR-03 短期记忆

- 保存当前会话中的上下文
- 支持最近若干轮摘要压缩

FR-04 长期记忆

- 存储用户画像、关注标的、偏好、历史行为摘要
- 为回答提供个性化参考

FR-05 记忆 API

- 对外提供记忆写入、读取、刷新与清理接口

8.3 文档处理与知识库

FR-06 文档上传

- 支持 PDF、Excel、HTML、TXT 等文件上传
- 记录文件元数据、来源、上传人、时间和标签

FR-07 文档解析

- 保留段落、标题、表格、页码和布局信息
- 对复杂表格和跨页内容进行尽可能稳定的结构化提取

FR-08 知识切分与索引

- 文档按语义块和结构块切分
- 生成向量索引与必要的结构化字段索引

8.4 Adaptive-RAG

FR-09 查询分类

- 系统根据查询复杂度判断检索模式
- 至少支持直接检索、多步检索、聚合分析三种路径

FR-10 多源检索

- 支持向量检索、关键词检索、元数据过滤
- 支持对不同数据源进行结果融合

FR-11 引用与可追溯

- 回答需返回引用片段、文档来源和必要的页码/位置

8.5 工具生态与 MCP

FR-12 工具注册

- 支持注册外部工具和内部服务
- 工具具备名称、描述、入参、出参、超时、权限等元信息

FR-13 工具路由

- Agent 可根据任务需要自动选择工具
- 支持失败重试、超时控制和错误回传

FR-14 MCP 兼容

- 系统预留 MCP Server 接入机制
- 支持将行情、规则、数据库等服务以统一协议接入

8.6 多模态能力

FR-15 图片/图表理解

- 支持对图表图片进行基础理解与字段提取
- 支持将图表理解结果融合进回答

FR-16 扩展预留

- 预留语音输入输出和更复杂视觉模型接入接口

8.7 推理与合规

FR-17 任务规划

- 对复杂问题生成中间步骤
- 支持检索、工具调用、汇总与校验等子任务编排

FR-18 反思与校验

- 生成答案后可执行自检
- 对低置信内容增加风险提示

FR-19 合规检查

- 基于规则库对生成内容进行预检
- 输出命中规则、潜在风险和建议复核点

8.8 管理与运维

FR-20 知识库管理

- 支持文档状态查看、重建索引、删除或停用

FR-21 规则库管理

- 支持规则录入、更新、版本管理和启停

FR-22 运行监控

- 支持查看请求日志、调用耗时、检索命中率、失败率等指标

9. 非功能需求

9.1 性能

- 常规问答接口平均响应时间目标小于 10 秒
- 文档上传后解析与索引流程支持异步执行

9.2 稳定性

- 单点服务异常不应导致整个系统不可用
- 工具调用失败需具备降级策略

9.3 可扩展性

- LLM、Embedding、向量库、工具协议可替换
- 支持后续新增 Agent、MCP Server 和多模态模型

9.4 安全与合规

- 支持鉴权、审计日志、敏感内容控制
- 用户数据与企业内部数据访问边界清晰

9.5 可观测性

- 支持日志、Tracing、指标监控
- 能追溯回答所依赖的文档和工具调用链路

10. 核心指标

- 研报问答准确率
- 引用命中率
- 文档解析成功率
- 合规预检召回率
- 平均响应耗时
- 用户使用频次与留存

11. 里程碑建议

里程碑 1: MVP 可用版

- 完成对话接口、文档解析、基础 RAG、合规预检、Docker 部署

里程碑 2: 增强检索版

- 完成查询分类、多路检索、记忆体系增强、规则库增强

里程碑 3: 平台扩展版

- 完成 MCP 接入、多模态理解、多 Agent 编排、监控与运营后台

12. 验收标准

- 用户可上传文档并完成索引
- 用户可针对文档和知识库进行问答，回答包含引用依据
- 系统可识别不同类型查询并选择对应检索路径
- 系统可输出基础合规预检结果

- 系统具备标准 API 与容器化部署能力

13. 风险与依赖

风险

- 文档解析质量不足会直接影响检索与回答质量
- 合规规则结构化程度不足会限制自动核查效果
- 多模型、多工具接入增加系统复杂度

依赖

- 可用的 LLM/Embedding 服务
- 可接入的内部研报和规则数据源
- 可维护的规则库与知识库治理流程

14. 后续研发建议

- 第一阶段优先把文档解析、检索链路和回答引用打稳
- 第二阶段增强查询路由、合规核查和记忆系统
- 第三阶段再接入 MCP、多模态与复杂 Agent 调度